

第 4 章 Kalman 滤波器

跟其他著名的理论（例如傅立叶变换，泰勒级数等等）一样，Kalman（卡尔曼）滤波器也是以一个人的名字命名的，即 匈牙利数学家 Rudolf Emil Kalman。现在要学习的 Kalman 滤波器，源于 Rudolf Emil Kalman 的博士论文以及 1960 年左右发表的论文^[13, 14]。简单来说，Kalman 滤波器是一个“optimal recursive data processing algorithm(最优自回归数据处理算法)”。对于很多问题，Kalman 滤波器都可以得到最优的（最小均方差）估计结果，效率最高甚至是最有用的。目前，Kalman 滤波器在许多领域具有广泛应用，包括机器人导航与控制、雷达跟踪系统等。近年来还被应用于计算机图像处理，如视频图像跟踪等。

Kalman 滤波器的推导有很多方法，采用最小二乘估计方法进行推导，先给出系统模型，再考虑由待估计状态变化引起的向前一步状态预测问题，进而给出 Kalman 滤波器五个著名的递推公式。

例 4.1 下面来看一下如果实际测量数据发生突变，利用最小二乘方法得到的结果如何呢？真实值在第 501 个点处由 20 跳变至 30，如图 4.1 所示，噪声方差不变，仍为 2。

测量方程为 $Z(k) = \theta + N(k)$ ，测量矩阵为 $H(k) = 1$ ，测量噪声方差为 $R(k) = 2$ ，因为测量矩阵是一个标量，权值也是一个标量，取为测量噪声方差的倒数 0.5， $H^T(k)W(k)H(k)$ 计算后也是一个标量，所以 M_k 也是一个标量，其初始值设为 1000。




图 3.10 传感器得到的具有突变特征的数据

首先需要用模拟的方法产生具有突变特征的传感器数据, 前500个数据的真值为20, 后500个数据的真值为30, 传感器测量噪声的方差为2, 程序如下

```
clc
clear
t=0.01:0.01:10;
za=[20+sqrt(2)*randn(500,1);30+sqrt(2)*randn(500,1)];
```

接下来利用递推最小二乘方法估计具有突变特征的数据真值, 程序中 h 表示 $H(k)$, w 表示 $W(k)$, M 表示 M_k , $ea0$ 为待估计量的初值, 在实现递推估计的循环中第 i 次的估计结果用 $ea(i)$ 表示, 程序如下:

```
h=1;
w=0.5;
M=1000;
ea0=0;
for i=1:1000
M=inv(inv(M)+h'*w*h);
ea(i)=ea0+M*h'*w*(za(i)-h*ea0);
ea0=ea(i);
end
plot(ea)
```

可以看到, 具有递推效果的最小二乘估计方法能够发现真实值的变化, 并将这种变化反映在估计值中。但经过后 500 个递推估计, 还是没有得到较为准确的估计 (真实值是 30)。

如果真实值的变化再复杂一些, 如很多信号的变化都满足一阶马尔科夫过程 $\theta(k+1)=p*\theta(k)+w(k)$, 可以推断其估计的结果会更差。为什么会这样呢? 回忆一下, 最小二乘估计所研究的问题只给出了测量方程, 描述的是测量数据和待估计量的真值之间的线性关系, 而且, 由于认为被估计量 θ 恒定不变, 那么使用递推最小二乘估计方法, 其实也是默认待估计量并不改变, 只是在这个过程中估计结果随着时间的变化不断向真值靠近。所以在实际应用的时候, 如果待估计量发生了改变, 不考虑这种变化就不会得到很好的结果。那么如何解决这个问题呢? 本章 Kalman 滤波器的内容表明, 该方法就是研究待估计量随着时间而改变情况下的估计。




图 4.1 具有突变特征变量的估计结果

4.1 系统模型描述

上一章假设待估计变量 θ 不变，与之不同的是，本章将认为待估计量 x 随着时间发生变化。为与前一章待估计量 θ 相区别，本章使用 x 表示待估计量，写成离散形式是 $x(k)$ ，并且， $x(k)$ 含有不确定的变化。估计含有噪声变量的方法叫做贝叶斯估计，Kalman 滤波器也可以通过贝叶斯估计推导得到，本书使用第 3 章最小二乘估计的结果来推导 Kalman 滤波器，这样更简洁，更易于理解。

假设有线性离散系统的过程模型及测量模型如下：

$$x(k+1) = A(k)x(k) + w(k) \quad (4-1)$$

$$z(k) = C(k)x(k) + v(k) \quad (4-2)$$

其中 $x(k)$ 是待估计量， $z(k)$ 是通过传感器得到的测量数据。一般将 (4-1) 称为系统过程模型，指的是系统中待估计状态随时间变化的规律。前一时刻 k 的状态 $x(k)$ ，在下一时刻即 $k+1$ 时刻会变成 $x(k+1)$ ，称 $A(k)$ 为过程矩阵，表示状态变换的关系。 $w(k)$ 叫做过程噪声，表示 $x(k)$ 变成 $x(k+1)$ 过程中的不确定程度。(4-2) 称为测量模型， $C(k)$ 为测量矩阵， $v(k)$ 为测量噪声。假设 $w(k)$ 和 $v(k)$ 是零均值、不相关白噪声，并且协方差矩阵已知，分别用 $Q(k)$ 和 $R(k)$ 表示，即

$$\begin{aligned}
w(k) &\sim (0, Q(k)) \\
v(k) &\sim (0, R(k)) \\
E[w(k)w^T(j)] &= Q(k)\delta(k-j) \\
E[v(k)v^T(j)] &= R(k)\delta(k-j) \\
E[w(k)v^T(j)] &= 0
\end{aligned} \tag{4-3}$$

其中, $\delta(k-j)$ 是 Kronecker- δ 函数, 即如果 $k=j$ 那么 $\delta(k-j)=1$, 如果 $k \neq j$ 那么 $\delta(k-j)=0$ 。这样做的目的是, 在已知系统方程 (4-1)、(4-2) 和含噪声的测量 $z(k), k=1, 2, 3, \dots$ 基础上估计状态 $x(k)$ 。状态量的具体物理含义取决于要研究的问题, 如果关注的是跟踪目标问题, 状态量一般取位移、速度和加速度等。

接下来介绍两个量的表示方法^[15], 一个是后验估计 $\hat{x}(k|k)$, 一个是先验估计 $\hat{x}(k|k-1)$, 二者的区别在于测量与待估计量之间的时间关系。 $\hat{x}(k|k)$ 是使用 k 时刻及其以前各个时刻的测量值 $z(k)$ 估计 k 时刻的状态 $x(k)$ 期望值, 即 $\hat{x}(k|k) = E[x(k)|z(1), z(2), \dots, z(k)]$, 而 $\hat{x}(k|k-1)$ 是使用 k 时刻以前的各个时刻 (注意: 不包括 k 时刻) 的测量值, 来估计 k 时刻的状态 $x(k)$ 期望值, 即 $\hat{x}(k|k-1) = E[x(k)|z(1), z(2), \dots, z(k-1)]$, 注意到, 先验估计 $\hat{x}(k|k-1)$ 和后验估计 $\hat{x}(k|k)$ 都是同一个量的 $x(k)$ 估计, 然而 $\hat{x}(k|k-1)$ 考虑的是测量值 $z(k)$ 之前的估计, 也称之为向前一步预测估计, 而 $\hat{x}(k|k)$ 考虑的是测量值 $z(k)$ 之后的估计。可见需要用更多地信息计算 $\hat{x}(k|k)$, 所以自然希望 $\hat{x}(k|k)$ 比 $\hat{x}(k|k-1)$ 更好。那么应该设计什么估计方法来得到 $\hat{x}(k|k)$ 和 $\hat{x}(k|k-1)$ 呢? $\hat{x}(k|k)$ 的估计是不是比 $\hat{x}(k|k-1)$ 更好呢? 下面就来回答这两个问题。

4.2 向前一步预测估计 $\hat{x}(k|k-1)$ 的求法

重新考虑上一章最小二乘估计的问题, 已知含有噪声测量, 使用 (3-42) - (3-46) 可以得到最优估计。但上一章假设待估计量不随时间而改变, 而本章研究的待估计量 $x(k)$ 随着时间的推移按照 (4-1) 而改变, 也就是说, 在 k 时刻的测量 $z(k)$ 到来之前, 状态 $x(k)$ 在 $k-1$ 时刻的估计值 $\hat{x}(k-1|k-1)$ 会随着时间的推移而改变, 在 $z(k)$ 到来时, $\hat{x}(k-1|k-1)$ 已经变化为 $\hat{x}(k|k-1)$, 改变遵循 (4.1) 系统状态转移方程:

$$\hat{x}(k|k-1) = A(k-1)\hat{x}(k-1|k-1) \tag{4-4}$$

如果已知 $\hat{x}(k-1|k-1)$ 的估计方差

$$P(k-1|k-1) = E[(x(k-1) - \hat{x}(k-1|k-1))(x(k-1) - \hat{x}(k-1|k-1))^T] \tag{4-5}$$

那么 $\hat{x}(k|k-1)$ 的估计方差 $P(k|k-1)$ 是多少呢？ $P(k|k-1)$ 的定义式应为：

$$P(k|k-1) = E[(x(k) - \hat{x}(k|k-1))(x(k) - \hat{x}(k|k-1))^T] \quad (4-6)$$

将 (4-1) 和 (4-4) 代入 (4-6)，得到：

$$\begin{aligned} P(k|k-1) &= E[(A(k-1)x(k-1) + w(k-1) - A(k-1)\hat{x}(k-1|k-1)) \\ &\quad \times (A(k-1)x(k-1) + w(k-1) - A(k-1)\hat{x}(k-1|k-1))^T] \\ &= E[(A(k-1)(x(k-1) - \hat{x}(k-1|k-1)) + w(k-1))(A(k-1)(x(k-1) - \hat{x}(k-1|k-1)) + w(k-1))^T] \end{aligned}$$

考虑到状态与过程噪声不相关，将上式两个括号相乘，得到：

$$\begin{aligned} P(k|k-1) &= A(k-1)E[(x(k-1) - \hat{x}(k-1|k-1))(x(k-1) - \hat{x}(k-1|k-1))^T]A^T(k-1) \\ &\quad + E[w(k-1)w^T(k-1)] \end{aligned}$$

注意到上式中第一项的中间项为 $\hat{x}(k-1|k-1)$ 的估计方差 $P(k-1|k-1)$ ，并利用 (4-3) 中过程噪声的方差项，可以得到

$$P(k|k-1) = A(k-1)P(k-1|k-1)A^T(k-1) + Q(k-1) \quad (4-7)$$

总结一下，在 $z(k)$ 到来时， $\hat{x}(k-1|k-1)$ 已经变化为 $\hat{x}(k|k-1)$ ，其估计方差也由 $P(k-1|k-1)$ 转变为 $P(k|k-1)$ ，为读者阅读方便，将其转换公式重写如下：

$$\hat{x}(k|k-1) = A(k-1)\hat{x}(k-1|k-1) \quad (4-8)$$

$$P(k|k-1) = A(k-1)P(k-1|k-1)A^T(k-1) + Q(k-1) \quad (4-9)$$

4.3 更新估计 $\hat{x}(k|k)$ 的求法

继续考虑在 $\hat{x}(k|k-1)$ 的情况下，如果又得到了 k 时刻的测量 $z(k)$ ，如何利用新到的测量值来得到更准确的估计 $\hat{x}(k|k)$ 呢？这时候，就可以很方便的利用上一章中学习到的最小二乘估计方法了，在 (3-42) - (3-47) 中，用 $\hat{x}(k|k-1)$ 代替 $\hat{\theta}(k-1)$ ， $\hat{x}(k|k)$ 代替 $\hat{\theta}(k)$ ，用 $P(k|k-1)$ 代替 $P(k-1)$ ， $P(k|k)$ 代替 $P(k)$ ，对 (3-42)、(3-44)、(3-47) 按如下形式重写，其余的公式变换与之相似。

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)(z(k) - C(k)\hat{x}(k|k-1)) \quad (4-10)$$

$$K(k) = P(k|k-1)C^T(k) \left(C(k)P(k|k-1)C^T(k) + R(k) \right)^{-1} \quad (4-11)$$

$$P(k|k) = (I - K(k)C(k))P(k|k-1) \quad (4-12)$$

下面，来仔细分析一下滤波增益 $K(k)$ 。用下式表示预测的测量：

$$z(k|k-1) = C(k)\hat{x}(k|k-1) \quad (4-13)$$

虽然预测的测量与真实测量会有不同，但这个量还是反映了预测状态的结果。设 P_{xz} 定义为状态预测与测量预测的协方差，则：

$$P_{xz} = E \left[(x(k) - \hat{x}(k|k-1))(z(k) - z(k|k-1))^T \right] \quad (4-14)$$

将 (4-2) 和 (4-13) 代入 (4-14), 得:

$$\begin{aligned} P_{xz} &= E \left[(x(k) - \hat{x}(k|k-1))(C(k)x(k) + v(k) - C(k)\hat{x}(k|k-1))^T \right] \\ &= E \left[(x(k) - \hat{x}(k|k-1))(C(k)(x(k) - \hat{x}(k|k-1)) + v(k))^T \right] \end{aligned}$$

因为 $x(k)$ 与 $v(k)$ 之间不相关, 则:

$$P_{xz} = P(k|k-1)C^T(k) \quad (4-15)$$

再定义预测测量的方差为:

$$P_{zz} = E \left[(z(k) - z(k|k-1))(z(k) - z(k|k-1))^T \right] \quad (4-16)$$

同样, 将 (4-2) 和 (4-13) 代入 (4-16) 经整理后得:

$$P_{zz} = C^T(k)P(k|k-1)C(k) + R(k) \quad (4-17)$$

因此, 滤波增益也可以表示为:

$$K(k) = P_{xz}P_{zz}^{-1} \quad (4-18)$$

再来看一下 (4-12), 将右边等式展开得:

$$\begin{aligned} P(k|k) &= P(k|k-1) - K(k)C(k)P(k|k-1) \\ &= P(k|k-1) - K(k)P_{xz}^T \end{aligned} \quad (4-19)$$

上式考虑到 $P(k|k-1) = P^T(k|k-1)$, 即 $P(k|k-1)$ 为对称矩阵。又在 (4-18) 等式两边右乘 P_{zz} 得:

$$P_{xz} = K(k)P_{zz} \quad (4-20)$$

将 (4-20) 代入 (4-19), 还可以得到 $P(k|k)$ 的另一个表达式

$$P(k|k) = P(k|k-1) - K(k)P_{zz}K^T(k) \quad (4-21)$$

(4-18)、(4-19)、(4-21) 是利用 P_{xz} 、 P_{zz} 求增益 $K(k)$ 及状态估计方差 $P(k|k)$ 的方法。有时通过贝叶斯估计的方法获得 P_{xz} 、 P_{zz} 后, 就可以利用 (4.18) 式滤波增益 $K(k)$, 而相应的估计方差即为 (4-21) 或 (4-19)。这个方法在第 5 章的非线性滤波器中会使用。

4.4 离散 Kalman 滤波器

现将离散 Kalman 滤波器总结如下:

1. 系统方程为

$$\begin{aligned}
x(k+1) &= A(k)x(k) + w(k) \\
z(k) &= C(k)x(k) + v(k) \\
E[w(k)w^T(j)] &= Q(k)\delta(k-j) \\
E[v(k)v^T(j)] &= R(k)\delta(k-j) \\
E[w(k)v^T(j)] &= 0
\end{aligned} \tag{4-22}$$

2. Kalman 滤波器初始化

$$\begin{aligned}
\hat{x}(0|0) &= E[x(0)] \\
P(0|0) &= E[(x(0) - \hat{x}(0|0))(x(0) - \hat{x}(0|0))^T]
\end{aligned} \tag{4-23}$$

3. Kalman 滤波器每一步计算如下, 其中 $k=1,2,3,\dots$

$$\hat{x}(k|k) = \hat{x}(k|k-1) + K(k)(z(k) - C(k)\hat{x}(k|k-1)) \tag{4-24}$$

$$\hat{x}(k|k-1) = A(k-1)\hat{x}(k-1|k-1) \tag{4-25}$$

$$K(k) = P(k|k-1)C^T(k) \left(C(k)P(k|k-1)C^T(k) + R(k) \right)^{-1} \tag{4-26}$$

$$P(k|k-1) = A(k-1)P(k-1|k-1)A^T(k-1) + Q(k-1) \tag{4-27}$$

$$P(k|k) = (I - K(k)C(k))P(k|k-1) \tag{4-28}$$

使用下面的 MATLAB 函数实现 Kalman 滤波器, 函数输入为系统矩阵的参数, 其中 A 表示过程矩阵 $A(k-1)$, C 表示测量矩阵 $C(k)$, Q 表示过程噪声方差 $Q(k-1)$, R 表示测量噪声方差 $R(k)$ 。函数的变量 xe 表示前一步的状态估计值 $\hat{x}(k-1|k-1)$, p 表示前一步的状态估计方差 $P(k-1|k-1)$, z 表示当前测量值 $z(k)$ 。函数的输出包括三个量, 分别是当前步的状态估计值 $\hat{x}(k|k)$ 、向前一步的递推状态估计方差 $P(k|k-1)$ 以及当前步的状态估计方差 $P(k|k)$, 分别用 xe、p1、pk 表示。另外, 使用函数 inv 实现矩阵求逆。

```
function [xe, pk, p1]=kalmanfun(A, C, Q, R, xe, z, p)
```

```
%This function is to calculate the estimation state by Kalman filter.
```

```
xe=A*xe; %根据 (4-25) 计算向前一步预测  $\hat{x}(k|k-1)$ 
```

```
P1=A*p*A'+Q; %根据 (4-27) 计算向前一步估计  $P(k|k-1)$ 
```

```
K=p1*C'*inv(C*p1*C'+R); %根据 (4-26) 计算估计增益  $K(k)$ 
```

```
xe=xe+K*(z-C*xe); % 根据 (4-25) 计算估计  $\hat{x}(k|k)$ 
```

```
pk=(eye(size(p1))-1*C)*p1; % 根据 (4-28) 计算估计方差  $P(k|k)$ 
```

第 3 章在推导递推最小二乘法时, 增益的方差还有另外两种形式, 所以 Kalman 滤波器的增益和估计方差也还有另外两种形式:

$$K(k) = P(k|k)C^T(k)R^{-1}(k) \tag{4-29}$$

和

$$P^{-1}(k|k) = P^{-1}(k|k-1) + C^T(k)R^{-1}(k)C(k) \quad (4-30)$$

计算表明,估计方差 $P(k|k)$ 是一个对称矩阵。从(4-26)-(4-28)还可以看出, $P(k|k)$ 、 $K(k)$ 和 $P(k|k-1)$ 的计算不依赖于测量 $z(k)$, 仅依赖于系统参数, 因此当系统参数已知时, 可以在系统测量到达并估计之前离线地计算。在系统运行时仅计算 $\hat{x}(k|k)$ 和 $\hat{x}(k|k-1)$, 如果 Kalman 滤波器在计算量有严格要求的嵌入式系统中运行, 这一点决定系统是否能够实时运行。此外, Kalman 滤波器的工作性能可以在实施运行前评估, 这是因为代表滤波器的估计的准确度 $P(k|k)$ 也不取决于测量值, 可以脱机计算。

当 $k \rightarrow \infty$ 时, $P(k|k)$ 的收敛值 $P(\infty|\infty)$ 表示系统的稳态估计方差。先来看一下当 $k \rightarrow \infty$ 时, $P(k|k-1)$ 的稳态值, 将(4-27)式中的 k 变为 $k+1$, 再将式(4-28)代入, 并利用(4-28)式的滤波器增益得到:

$$\begin{aligned} P(k+1|k) &= A(k)P(k|k)A^T(k) + Q(k) \\ &= A(k)(I - K(k)C(k))P(k|k-1)A^T(k) + Q(k) \\ &= A(k)P(k|k-1)A^T(k) - A(k)K(k)C(k)P(k|k-1)A^T(k) + Q(k) \\ &= A(k)P(k|k-1)A^T(k) \\ &\quad - A(k)P(k|k-1)C^T(k)(R(k) + C(k)P(k|k-1)C^T(k))^{-1}C(k)P(k|k-1)A^T(k) + Q(k) \end{aligned} \quad (4-31)$$

如果协方差矩阵收敛, 即 $k \rightarrow \infty$, $P(k+1|k) = P(k|k-1) \rightarrow P_\infty$, 上式变为:

$$P_\infty = A(k)P_\infty A^T(k) - A(k)P_\infty C^T(k)(R(k) + C(k)P_\infty C^T(k))^{-1}C(k)P_\infty A^T(k) + Q(k) \quad (4-32)$$

这是著名的离散 Riccati 方程, 利用该式可以判断估计结果的好坏, 还可以计算稳态的估计方差 $P(\infty|\infty)$ 和稳态增益 $K(\infty)$ 来简化 Kalman 滤波器的计算。

例 4.1 假设对于无噪声牛顿动力学系统, 位置、速度、恒加速度分别为 r 、 v 、 a 。这个系统可以描述为:

$$\begin{bmatrix} \dot{r} \\ \dot{v} \\ \dot{a} \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} r \\ v \\ a \end{bmatrix} \quad (4-33)$$

即

$$\dot{x} = Fx \quad (4-34)$$

该系统离散化(采样时间为 T)后可以写为

$$x(k+1) = Ax(k) \quad (4-35)$$

其中 A 为

$$A = \exp(FT) = I + FT + \frac{(FT)^2}{2!} + \dots \quad (4-36)$$

得到:

$$A = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix} \quad (4-37)$$

假设测量位置的噪声方差为 σ^2 ，则系统的测量方程可写为：

$$\begin{aligned} z(k) &= C(k)x(k) + v(k) \\ &= \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} x(k) + v(k) \end{aligned} \quad (4-38)$$

其中，测量噪声为：

$$v(k) \sim (0, R(k)) \quad (4-39)$$

根据题意测量噪声方差为

$$R(k) = \sigma^2 \quad (4-40)$$

下面来研究一下估计方差的变化，假设向前一步预测估计方差为

$$P(k|k-1) = \begin{bmatrix} P_{11}(k|k-1) & P_{21}(k|k-1) & P_{31}(k|k-1) \\ P_{12}(k|k-1) & P_{22}(k|k-1) & P_{32}(k|k-1) \\ P_{13}(k|k-1) & P_{23}(k|k-1) & P_{33}(k|k-1) \end{bmatrix} \quad (4-41)$$

状态估计方差为

$$P(k|k) = \begin{bmatrix} P_{11}(k|k) & P_{21}(k|k) & P_{31}(k|k) \\ P_{12}(k|k) & P_{22}(k|k) & P_{32}(k|k) \\ P_{13}(k|k) & P_{23}(k|k) & P_{33}(k|k) \end{bmatrix} \quad (4-42)$$

先将 $C(k) = [1 \ 0 \ 0]$ 代入滤波增益 (4-26)，得到

$$K(k) = \begin{bmatrix} P_{11}(k|k-1) \\ P_{12}(k|k-1) \\ P_{13}(k|k-1) \end{bmatrix} \frac{1}{P_{11}(k|k-1) + \sigma^2} \quad (4-43)$$

将上式代入 (4-28)，得到

$$P(k|k) = P(k|k-1) - \frac{1}{P_{11}(k|k-1) + \sigma^2} \begin{bmatrix} P_{11}(k|k-1) & 0 & 0 \\ P_{12}(k|k-1) & 0 & 0 \\ P_{13}(k|k-1) & 0 & 0 \end{bmatrix} P(k|k-1) \quad (4-44)$$

将上式的后两项相乘后得到

$$\begin{aligned} P(k|k) &= P(k|k-1) \\ &- \frac{1}{P_{11}(k|k-1) + \sigma^2} \begin{bmatrix} P_{11}^2(k|k-1) & P_{11}(k|k-1)P_{12}(k|k-1) & P_{11}(k|k-1)P_{13}(k|k-1) \\ P_{12}(k|k-1)P_{11}(k|k-1) & P_{22}^2(k|k-1) & P_{12}(k|k-1)P_{13}(k|k-1) \\ P_{13}(k|k-1)P_{11}(k|k-1) & P_{13}(k|k-1)P_{12}(k|k-1) & P_{33}^2(k|k-1) \end{bmatrix} \end{aligned} \quad (4.45)$$

用这个表达式说明估计方差从 $P(k|k-1)$ 到 $P(k|k)$ 的迹在减小。 $P(k|k-1)$ 的迹为

$$Tr(P(k|k-1)) = P_{11}(k|k-1) + P_{22}(k|k-1) + P_{33}(k|k-1) \quad (4-46)$$

从方程 (4-45) 可以看出, $P(k|k)$ 的迹为

$$\begin{aligned} Tr(P(k|k)) &= P_{11}(k|k) + P_{22}(k|k) + P_{33}(k|k) \\ &= Tr(P(k|k-1)) - \frac{P_{11}^2(k|k-1) + P_{22}^2(k|k-1) + P_{33}^2(k|k-1)}{P_{11}(k|k-1) + \sigma^2} \end{aligned} \quad (4-47)$$

当得到一个新的观测值时, 希望状态的估计值变得更为准确, 即希望协方差减小, 上述方程表明它的确减小了, 即 $Tr(P(k|k)) < Tr(P(k|k-1))$ 。从 $P(k|k-1) = A(k-1)P(k-1|k-1)A^T(k-1) + Q(k-1)$ 还可以看出 $Tr(P(k-1|k)) > Tr(P(k-1|k-1))$, 也就是说, 在向前一步预测阶段, 估计方差变大了, 而进行测量后, 估计方差又会减小。

例 4.2 考虑如下游走模型的标量系统

$$x(k+1) = x(k) + w(k)$$

$$z(k) = x(k) + v(k)$$

$$w(k) \sim (0, 9)$$

$$v(k) \sim (0, 4)$$

这是一个很简单但是在很多应用中会碰到的系统。例如, 它可能代表直接测量的缓慢变量 $x(k)$, 其变化由噪声项决定, 测量误差由测量噪声项决定, 问题是: 求解滤波增益的稳态值 K_∞ 。

解: 由系统可知, $A = C = 1, Q = 9, R = 4$, 代入 (4-31), 得到 $P_\infty = 12$, 再将 P_∞ 代入

$$(4-26) \text{ 得到的 } K_\infty = \frac{12}{12+4} = 0.75。$$

进一步还可以将 P_∞ 和 K_∞ 代入 (4-28) 得状态估计方差稳态值 $P(\infty|\infty)$, 得:

$$P(\infty|\infty) = (I - K_\infty C)P_\infty = (1 - 0.75) \times 12 = 3$$

除了上述数值计算方法之外, 使用程序进行仿真, 通过迭代计算 (4-27) 和 (4-28), 也可以得到估计方差的稳态值。首先介绍一下下面的函数, 其中 A, C, Q, R 分别是系统参数, I 是可以设置的循环次数, p0 是估计方差初值。将下面的函数保存为以 `steadycov` 命名的 m 文件, 根据不同的系统进行参数设置就会得到向前一步预测估计方差、状态估计方差以及滤波器增益向稳态值收敛的过程, MATLAB 程序中函数的输出量 pp1, pp, KK。

```
function [pp1, pp, KK]=steadycov(A, C, Q, R, I, p0)
```

```
p=p0*ones(size(A));
```

```
pp1=[];pp=[];KK=[];
```

```
for i=1:I
```

```
pp1=A*p*A'+Q;
```

```

K=p1*C'*inv(C'*p1*C+R);
p=(eye(size(A))-K*C)*p1;
pp1=[pp1 diag(p1)];
pp=[pp diag(p)];
KK=[KK K];

```

```
end
```

下一段程序是调用上面函数的主程序，根据例题 4.2 设置相应的参数， $A=1$ ， $C=1$ ， $Q=9$ ， $R=4$ ，循环次数 I 和估计方差的初值 P_0 都设置为 10，调用函数后，对计算结果画图并进行适当的标注，即可得到如图 4.1 所示的结果。

```

clc
clear
A=1;C=1;Q=9;R=4;I=10;p0=10;
[pp1, pp, KK]=steadycov(A, C, Q, R, I, p0);
subplot(3, 1, 1);plot(pp1);xlabel('k'), ylabel('向前一步预测估计方差')
subplot(3, 1, 2);plot(pp);xlabel('k'), ylabel('状态估计方差')
subplot(3, 1, 3);plot(KK);xlabel('k'), ylabel('滤波器增益')

```




图 4.1 稳态估计结果图

可以看到结果收敛的非常快，只要经过 3、4 步的时间就可以收敛至稳态值。根据这些稳态值，就可以简化 Kalman 滤波器计算过程。利用滤波器增益的稳态值，将 (4-24)、(4-25)

状态估计的过程简化如下

$$\hat{x}(k|k) = \hat{x}(k-1|k-1) + 0.75(z(k) - \hat{x}(k-1|k-1)) \quad (4-48)$$

在每一步的测量到来之后，可以利用上式快速得到当前步的状态估计，计算非常简单，这也是 Kalman 可以在很多情况下都能够做到实时估计的原因。

4.5 小结

本章介绍了离散的 Kalman 滤波器，在过去的几十年里，这种估计方法几乎应用于工程的各个领域，比如跟踪、导航等。Kalman 的滤波方程可以写出不同的形式，但在功能上是等价的。

Kalman 滤波器要求系统参数是已知的，如果参数未知，或者参数的值有误差，Kalman 滤波器就不能得到最优估计，甚至无法得到状态的估计，即发散。但是，Kalman 滤波器对参数的误差还是有一定的容忍度的，虽然系统参数有误差时不能得到最优估计，但很多时候都能获得和真值还算相近的估计，再加上 Kalman 可以进行实时的估计，因此，在很多需要实时处理的应用中使用非常广泛。